

Table of Contents

Формулы к экзамену по МО — шпаргалка

Компаньон к ANSWERS.md. Формат: только формулы + 1-2 строки контекста. Для повторения в последний день. Нотация: $X \in \mathbb{R}^{N \times d}$ — данные, N — объекты, d — признаки, y — метки, w, θ — параметры. Горбаченковская нотация в скобках: ℓ вместо N , n вместо d , F вместо X , X^ℓ — выборка, Q — эмпирический риск.

0. Базовая статистика

Среднее: $\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$

Дисперсия (выборочная, несмещ.): $s^2 = \frac{1}{N-1} \sum (x_i - \bar{x})^2$

Ковариация: $\text{Cov}(X, Y) = \frac{1}{N-1} \sum (x_i - \bar{x})(y_i - \bar{y})$

Корреляция Пирсона: $r = \frac{\text{Cov}(X, Y)}{s_X s_Y} \in [-1, 1]$

z-score: $z_i = \frac{x_i - \bar{x}}{s}$

Межквартильный размах: $\text{IQR} = Q_3 - Q_1$. Выбросы по правилу Тьюки:
 $x < Q_1 - 1.5 \text{IQR}$ или $x > Q_3 + 1.5 \text{IQR}$.

1. Подготовка данных

Масштабирование

Min-Max: $x' = \frac{x - \min}{\max - \min} \in [0, 1]$

Standard (z-score): $x' = \frac{x - \mu}{\sigma}$

Robust: $x' = \frac{x - \text{median}}{\text{IQR}}$

Max-abs: $x' = x / \max(|x|) \in [-1, 1]$

Нормализация L2 по строке: $x' = x / \|x\|_2$

Кодирование

One-Hot: категория $c \in \{1, \dots, K\} \rightarrow$ вектор длины K с единицей на позиции c .

Target Encoding (регуляр.): $\text{enc}(c) = \frac{n_c \dot{y}_c + m \dot{y}}{n_c + m}$, m — сила сглаживания.

РСА (главные компоненты)

Центрирование: $X_c = X - \hat{X}$

Ковариация: $\Sigma = \frac{1}{N-1} X_c^\top X_c$

Разложение: $\Sigma = V \Lambda V^\top$, $\Lambda = \text{diag}(\lambda_1 \geq \dots \geq \lambda_d)$.

Проекция: $Z = X_c V_k$, $V_k \in \mathbb{R}^{d \times k}$.

Доля объяснённой дисперсии: $\frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^d \lambda_j}$

Mutual Information / Entropy

Энтропия: $H(X) = - \sum_x p(x) \log p(x)$

Условная: $H(Y|X) = - \sum_{x,y} p(x,y) \log p(y|x)$

МИ: $I(X;Y) = H(Y) - H(Y|X) = H(X) + H(Y) - H(X,Y)$

2. Регрессия

Линейная (OLS)

Модель: $\hat{y} = w^\top x + b$

Функционал: $Q(w) = \frac{1}{N} \sum (y_i - w^\top x_i - b)^2 = \frac{1}{N} \|y - Xw\|^2$

Аналитич. решение (нормальное уравнение): $\hat{w} = (X^\top X)^{-1} X^\top y$

Через псевдообращение: $\hat{w} = X^+ y$, $X^+ = (X^\top X)^{-1} X^\top$.

Градиент: $\nabla_w Q = \frac{2}{N} X^T (Xw - y)$

Регуляризованная

Ridge (L2): $\min_w \|y - Xw\|^2 + \lambda \|w\|_2^2, \hat{w} = (X^T X + \lambda I)^{-1} X^T y$

Lasso (L1): $\min_w \|y - Xw\|^2 + \lambda \|w\|_1$ (нет closed-form; координатный спуск).

Elastic Net: $\min_w \|y - Xw\|^2 + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2$.

Метрики регрессии

MSE: $\frac{1}{N} \sum (y_i - \hat{y}_i)^2$

RMSE: $\sqrt{\text{MSE}}$

MAE: $\frac{1}{N} \sum |y_i - \hat{y}_i|$

MAPE: $\frac{100\%}{N} \sum \left| \frac{y_i - \hat{y}_i}{y_i} \right|$

R^2 : $1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$

Adjusted R^2 : $1 - (1 - R^2) \frac{N - 1}{N - d - 1}$

Логистическая регрессия

Сигмоида: $\sigma(z) = \frac{1}{1 + e^{-z}}, \sigma'(z) = \sigma(z)(1 - \sigma(z))$

Модель: $p(y=1|x) = \sigma(w^T x + b)$

Правдоподобие (BCE): $Q(w) = -\frac{1}{N} \sum [y_i \log \hat{p}_i + (1 - y_i) \log (1 - \hat{p}_i)]$

Градиент: $\nabla_w Q = \frac{1}{N} X^T (\hat{p} - y)$

Softmax (многоклассовая): $p(y=k|x) = \frac{e^{w_k^T x}}{\sum_j e^{w_j^T x}}$

Cross-entropy (многоклас.): $Q = -\frac{1}{N} \sum_i \sum_k y_{ik} \log \hat{p}_{ik}$

3. Классификация: расстояния, байес, kNN

Расстояния

Евклидово: $d_2(x, y) = \sqrt{\sum (x_j - y_j)^2}$

Манхэттен: $d_1(x, y) = \sum |x_j - y_j|$

Минковский: $d_p(x, y) = \left(\sum |x_j - y_j|^p \right)^{1/p}$

Чебышёва: $d_\infty = \max_j |x_j - y_j|$

Косинусное: $d_{\cos} = 1 - \frac{x^\top y}{\|x\| \|y\|}$

Махаланобис: $d_M(x, y) = \sqrt{(x - y)^\top \Sigma^{-1} (x - y)}$

Байес

Формула: $P(y|x) = \frac{P(x|y)P(y)}{P(x)}$

Байесовский классификатор: $\hat{y} = \arg \max_c P(c)P(x|c)$

Naïve Bayes: $P(x|c) = \prod_j P(x_j|c)$

Гауссовский NB: $P(x_j|c) = N(x_j; \mu_{jc}, \sigma_{jc}^2)$

Мультиномиальный NB: $P(x|c) \propto \prod_j p_{jc}^{x_j}$

Лапласово сглаживание: $\hat{p}_{jc} = \frac{n_{jc} + \alpha}{n_c + \alpha V}$

kNN

$\hat{y}(x) = \arg \max_c \sum_{i \in N_k(x)} w_i 1[y_i = c]$

Веса: $w_i = 1$ (uniform) или $w_i = 1/d(x, x_i)$ (distance).

Для регрессии: $\hat{y} = \frac{\sum w_i y_i}{\sum w_i}$

4. Деревья решений

Критерии разбиения

Энтропия: $H(S) = - \sum_c p_c \log_2 p_c$

Information Gain: $IG(S, A) = H(S) - \sum_v \frac{|S_v|}{|S|} H(S_v)$

Gini: $Gini(S) = 1 - \sum_c p_c^2 = \sum_c p_c(1 - p_c)$

Classification error: $E(S) = 1 - \max_c p_c$

MSE (для регрессии): $MSE(S) = \frac{1}{|S|} \sum (y_i - \hat{y}_s)^2$

Cost-Complexity Pruning (CART)

$$C_\alpha(T) = \sum_{t \in \text{leaves}} Q(t) + \alpha |T|$$

$|T|$ — число листьев, α — параметр сложности.

5. SVM

Жёсткий зазор

Гиперплоскость: $w^\top x + b = 0$

Условие: $y_i(w^\top x_i + b) \geq 1$

Задача: $\min_{w, b} \frac{1}{2} \|w\|^2$ при $y_i(w^\top x_i + b) \geq 1$

Ширина зазора: $\frac{2}{\|w\|}$

Мягкий зазор

$\min \frac{1}{2} \|w\|^2 + C \sum_i \xi_i$ при $y_i(w^\top x_i + b) \geq 1 - \xi_i, \xi_i \geq 0$

Hinge loss: $L = \max(0, 1 - y_i(w^\top x_i + b))$

Двойственная задача

$$\max_\alpha \sum_i \alpha_i - \frac{1}{2} \sum_{i, j} \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

$$0 \leq \alpha_i \leq C, \sum \alpha_i y_i = 0$$

$$\text{Решение: } w = \sum_i \alpha_i y_i x_i; \hat{y}(x) = \text{sign} \left(\sum_i \alpha_i y_i K(x_i, x) + b \right)$$

Ядра

$$\text{Линейное: } K(x, y) = x^T y$$

$$\text{Полиномиальное: } K(x, y) = (x^T y + c)^d$$

$$\text{RBF (Гауссово): } K(x, y) = \exp(-\gamma \|x - y\|^2)$$

$$\text{Сигмоидное: } K(x, y) = \tanh(\gamma x^T y + c)$$

6. Кластеризация

K-means

$$\text{Функционал: } Q = \sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2$$

$$\text{Обновление центра: } \mu_k = \frac{1}{|C_k|} \sum_{x \in C_k} x$$

Метрики качества

Silhouette: $s_i = \frac{b_i - a_i}{\max(a_i, b_i)} \in [-1, 1]$, a_i — ср. расстояние внутри кластера, b_i — до ближайшего чужого.

$$\text{Davies-Bouldin: } DB = \frac{1}{K} \sum_i \max_{j \neq i} \frac{s_i + s_j}{d(\mu_i, \mu_j)}$$

$$\text{Inertia (within-cluster sum of squares): } WCSS = \sum_k \sum_{x \in C_k} \|x - \mu_k\|^2$$

Иерархическая

$$\text{Single link: } d(A, B) = \min_{a \in A, b \in B} d(a, b)$$

$$\text{Complete link: } d(A, B) = \max d(a, b)$$

$$\text{Average link: } d(A, B) = \frac{1}{|A||B|} \sum d(a, b)$$

Ward: минимизация роста WCSS при слиянии.

DBSCAN

Параметры: ε (радиус), minPts (минимум соседей).

Core-point: $|N_\varepsilon(x)| \geq \text{minPts}$.

7. Метрики классификации

Матрица ошибок: TP, TN, FP, FN.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

$$\text{Precision} = \frac{TP}{TP + FP}$$

$$\text{Recall (TPR, Sensitivity)} = \frac{TP}{TP + FN}$$

$$\text{Specificity (TNR)} = \frac{TN}{TN + FP}, \text{FPR} = 1 - \text{TNR}.$$

$$F1 = \frac{2 \cdot P \cdot R}{P + R}$$

$$F\text{-beta} = (1 + \beta^2) \frac{P \cdot R}{\beta^2 P + R}$$

$$\text{Balanced accuracy} = \frac{1}{2} (\text{TPR} + \text{TNR})$$

$$\text{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

ROC-AUC: площадь под кривой TPR(FPR).

$$\text{Log-loss} = -\frac{1}{N} \sum [y_i \log p_i + (1 - y_i) \log (1 - p_i)]$$

$$\text{Brier} = \frac{1}{N} \sum (p_i - y_i)^2$$

8. Кросс-валидация

Схемы

k-Fold: k частей, каждая по очереди — тест; итого k моделей.

LOOCV: $k = N$.

Stratified k-Fold: сохраняет распределение классов.

Оценка

$$CV_k = \frac{1}{k} \sum_{j=1}^k Q_j^{\text{test}}$$

Nested CV: внешний (оценка обобщения) + внутренний (подбор гиперпараметров).

9. Ансамбли

Voting

Hard: $\hat{y} = \arg \max_c \sum_m 1[a_m(x) = c]$

Soft: $\hat{y} = \arg \max_c \sum_m w_m p_m(c|x)$

Bagging / Random Forest

$$a_{\text{bag}}(x) = \frac{1}{M} \sum_m a_m(x) \text{ (регрессия), } \arg \max \text{ голосов (классиф.)}$$

Вероятность попасть в бутстрэп: $1 - (1 - 1/N)^N \rightarrow 1 - 1/e \approx 0.632$.

OOB size: $\approx 0.368 N$.

Разложение variance: $\text{Var}(\hat{a}) = \rho \sigma^2 + \frac{1-\rho}{M} \sigma^2$.

AdaBoost (бинарный, $y \in \{-1, +1\}$)

Инициализация: $w_i^{(1)} = 1/N$

Взвешенная ошибка: $\varepsilon_m = \sum_i w_i^{(m)} 1[a_m(x_i) \neq y_i]$

Вес модели: $\alpha_m = \frac{1}{2} \ln \frac{1 - \varepsilon_m}{\varepsilon_m}$

Обновление весов: $w_i^{(m+1)} \propto w_i^{(m)} \exp(-\alpha_m y_i a_m(x_i))$

Итог: $a(x) = \text{sign}\left(\sum_m \alpha_m a_m(x)\right)$

Эквивалентная потеря: $\sum_i \exp(-y_i F(x_i))$

Gradient Boosting

$$F_0(x) = \arg \min_c \sum L(y_i, c)$$

$$\text{Псевдоостатки: } r_i^{(m)} = - \frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \Big|_{F=F_{m-1}}$$

$$\text{Для MSE: } r_i = y_i - F_{m-1}(x_i)$$

$$\text{Для logloss: } r_i = y_i - \sigma(F_{m-1}(x_i))$$

$$\text{Обновление: } F_m = F_{m-1} + \nu h_m, \nu \text{ — learning rate.}$$

$$\text{XGBoost objective: } L + \sum_m \Omega(h_m), \Omega(h) = \gamma T + \frac{\lambda}{2} \|w\|^2.$$

10. Нейронные сети

Нейрон

$$\text{Pre-activation: } z = w^\top x + b = \sum_j w_j x_j + b$$

$$\text{Активация: } y = \varphi(z)$$

$$\text{Слой: } z = Wx + b, y = \varphi(z), W \in \mathbb{R}^{H \times d}$$

$$\text{Параметров в слое: } H(d+1)$$

Активации

$$\text{Sigmoid: } \sigma(z) = \frac{1}{1 + e^{-z}}, \sigma' = \sigma(1 - \sigma)$$

$$\text{Tanh: } \tanh z = \frac{e^z - e^{-z}}{e^z + e^{-z}}, \tanh' = 1 - \tanh^2 z$$

$$\text{ReLU: } \max(0, z); \varphi' = 1[z > 0]$$

$$\text{Leaky ReLU: } \max(\alpha z, z), \alpha = 0.01$$

$$\text{ELU: } z \text{ если } z \geq 0, \text{ иначе } \alpha(e^z - 1)$$

$$\text{GELU: } z \cdot \Phi(z)$$

Softmax: $\text{softmax}(z)_k = \frac{e^{z_k}}{\sum_j e^{z_j}}$

Softplus: $\ln(1 + e^z)$

Инициализация

LeCun: $\text{Var}(W) = 1 / d_{\text{in}}$

Xavier/Glorot: $\text{Var}(W) = \frac{2}{d_{\text{in}} + d_{\text{out}}}$; равномерно $[\pm \sqrt{6 / (d_{\text{in}} + d_{\text{out}})}]$

He (Kaiming): $\text{Var}(W) = \frac{2}{d_{\text{in}}}$ (для ReLU)

Forward / Backward

Forward: $z^{(l)} = W^{(l)} h^{(l-1)} + b^{(l)}; h^{(l)} = \varphi(z^{(l)})$

Loss $\rightarrow$ dL:

Softmax + CE: $\delta^{(L)} = \hat{y} - y_{\text{onehot}}$

Sigmoid + BCE: $\delta^{(L)} = \hat{y} - y$

MSE + линейная: $\delta^{(L)} = \hat{y} - y$

Backward (рекурсия):

$$\frac{\partial L}{\partial W^{(l)}} = \delta^{(l)} (h^{(l-1)})^\top$$

$$\frac{\partial L}{\partial b^{(l)}} = \delta^{(l)}$$

$$\delta^{(l-1)} = (W^{(l)})^\top \delta^{(l)} \odot \varphi'(z^{(l-1)})$$

Обновление: $\theta \leftarrow \theta - \eta \nabla_\theta L$

Dropout

Тренировка: $\tilde{h} = h \odot m / (1 - p), m \sim \text{Bernoulli}(1 - p)$.

Инференс: без маски.

Batch Normalization

$$\hat{x} = \frac{x - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}, y = \gamma \hat{x} + \beta$$

μ_B, σ_B^2 — среднее и дисперсия по батчу.

11. Оптимизаторы

SGD / Momentum / Nesterov

SGD: $\theta_{t+1} = \theta_t - \eta g_t$

Momentum: $v_t = \mu v_{t-1} + g_t$; $\theta_{t+1} = \theta_t - \eta v_t$, $\mu \approx 0.9$

Nesterov: $v_t = \mu v_{t-1} + \nabla Q(\theta_t - \eta \mu v_{t-1})$

AdaGrad / RMSProp

AdaGrad: $G_t = G_{t-1} + g_t^2$, $\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{G_t + \varepsilon}} g_t$

RMSProp: $G_t = \rho G_{t-1} + (1 - \rho) g_t^2$, $\rho \approx 0.9$

Adam / AdamW

$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$

$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$

Bias correction: $\hat{m}_t = \frac{m_t}{1 - \beta_1^t}$, $\hat{v}_t = \frac{v_t}{1 - \beta_2^t}$

Adam: $\theta_{t+1} = \theta_t - \eta \frac{\hat{m}_t}{\sqrt{\hat{v}_t + \varepsilon}}$

AdamW (decoupled weight decay): $\theta_{t+1} = \theta_t - \eta \left(\frac{\hat{m}_t}{\sqrt{\hat{v}_t + \varepsilon}} + \lambda \theta_t \right)$

Дефолты: $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\varepsilon = 10^{-8}$, $\eta = 10^{-3}$.

LR Schedulers

Step decay: $\eta_t = \eta_0 \gamma^{\lfloor t/k \rfloor}$

Exp: $\eta_t = \eta_0 \gamma^t$

Cosine annealing: $\eta_t = \eta_{\min} + \frac{1}{2}(\eta_0 - \eta_{\min}) \left(1 + \cos \frac{\pi t}{T} \right)$

12. Полезные тождества

Log-sum-exp trick (численная устойчивость)

$$\log \sum_i e^{x_i} = m + \log \sum_i e^{x_i - m}, m = \max_i x_i$$

Sigmoid и softmax

$$\sigma(z) = \frac{e^z}{1 + e^z}, 1 - \sigma(z) = \sigma(-z)$$

$$\text{Производная: } \sigma'(z) = \sigma(z) \sigma(-z)$$

$$\text{Softmax + CE (для одного примера): } \frac{\partial L}{\partial z_k} = p_k - y_k$$

Chain rule

$$\frac{\partial L}{\partial x} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial x}$$

$$\text{Для векторов: } \nabla_x L = J_y^\top \nabla_y L$$

Производная нормы

$$\nabla_w \|w\|^2 = 2w$$

$$\nabla_w \|y - Xw\|^2 = 2X^\top (Xw - y)$$

Bias-Variance decomposition

$$E[(y - \hat{y})^2] = (E\hat{y} - y)^2 + E[(\hat{y} - E\hat{y})^2] + \sigma^2$$

13. Быстрая справка по гиперпараметрам

Алгоритм

Ridge

Lasso

LogReg

kNN

DT

RF

GB

SVM

K-means
DBSCAN
MLP (Adam)
CNN (SGD)

14. Мнемоники и соответствия

Горбаченко ↔ **стандарт**:

Горбаченко

ℓ

n

F

X^ℓ

$a(x)$

$Q(a, X^\ell)$

Универсальный чек-лист обучения модели: 1. EDA → пропуски, выбросы, распределения, корреляции. 2. Split (train/val/test), стратификация. 3. Pipeline: impute → encode → scale → feature_selection → model. 4. Baseline (простая модель). 5. Cross-validation для гиперпараметров. 6. Оценка на holdout test. 7. Интерпретация (permutation importance, SHAP).

Пороги тревоги:

- $R^2 < 0$ → модель хуже mean.
- Accuracy ≈ доля мажоритарного класса → ничего не выучила.
- Train loss → 0, val loss растёт → переобучение.
- Loss = NaN → lr слишком большой или деление на 0.
- Gradient norm → 0 или → ∞ → vanishing/exploding.